

ANÁLISIS POR COMPONENTES PRINCIPALES (PCA)

MÉTODO DE REDUCCIÓN

Prof. Luana Rolon
Prof. Agustina Gioria



¿QUÉ ES EL ANÁLISIS POR COMPONENTES PRINCIPALES?

El Análisis de Componentes Principales (PCA) es una técnica estadística que reduce la dimensionalidad de un conjunto de datos, conservando la mayor parte de la variabilidad. Lo logra encontrando nuevas variables (componentes principales) que son combinaciones lineales de las variables originales y que están no correlacionadas entre sí.

¿QUÉ ES EL ANÁLISIS POR COMPONENTES PRINCIPALES?

Dadas n observaciones de p variables, el PCA analiza si es posible representar bien esa información con un número menor de variables, construidas como combinaciones lineales de las originales. Esas nuevas variables tienen dos propiedades clave:

- Conservan la mayor parte de la variabilidad de los datos (la “información”, lo que queremos conservar al reducir datos es la capacidad de distinguir unas observaciones de otras).
- Son no correlacionadas entre sí: cada componente aporta información distinta, sin repetir lo que ya dijo otra.

Uso	Explicación simple
Simplificar datasets	Pasar de muchas variables a unas pocas, más fáciles de manejar.
Visualizar datos de alta dimensión	Con 2 componentes se puede hacer un gráfico en el plano de datos que originalmente tenían decenas de variables.
Eliminar redundancia	Si varias variables están muy correlacionadas (miden casi lo mismo), el PCA las “fusiona” en una sola.
Mejorar modelos de machine learning	Al reducir el ruido y la redundancia, los modelos suelen ser más estables y rápidos.
Descubrir variables latentes	Ayuda a identificar factores “ocultos” (no medidos directamente) que generan la variabilidad de los datos, como un “tamaño general”.

PCA

El PCA es una técnica de aprendizaje no supervisado y suele usarse como parte del análisis exploratorio de los datos: una primera mirada para describir e interpretar lo que tenemos, antes de modelar.

	Aprendizaje supervisado	Aprendizaje no supervisado (PCA)
Variables	Variables explicativas $X_1, X_2, \dots, X_p$ y una variable respuesta Y	Solo variables $X_1, X_2, \dots, X_p$. No hay Y
Objetivo	Predecir Y a partir de las X	Encontrar estructura: subgrupos, patrones, variables que se parecen
Ejemplos	Regresión, clasificación	PCA, clustering (agrupamiento)

Dato importante


El PCA **no requiere el supuesto de normalidad multivariante** de los datos. Es una técnica descriptiva: transforma y resume los datos que tenemos, no necesita que sigan una distribución en particular.

CONCEPTOS CLAVES APLICADOS AL PCA

- **Varianza:** es la "información" que el PCA intenta conservar. Los componentes salen ordenados según cuánta varianza captura cada uno: CP1 la mayor, CP2 la siguiente, y así.
- **Correlación:** es lo que hace que el PCA funcione. Si las variables están muy correlacionadas, cuentan la misma historia y unos pocos componentes alcanzan. En el ejemplo de las piezas, las correlaciones eran mayores a 0,98 y por eso CP1 explicó el 99,35 %.
- **Combinación lineal:** cada componente es una mezcla de todas las variables originales, con un peso para cada una. Ejemplo: $CP1 = 0,58 \cdot longitud + 0,58 \cdot ancho + 0,58 \cdot peso$. Los pesos son los que se leen para interpretar qué representa cada CP.
- **Centrar y estandarizar:** el PCA siempre centra los datos. Estandarizar es obligatorio cuando las variables tienen unidades distintas (mm y g, por ejemplo), porque si no domina la variable con números más grandes. En R: `scale. = TRUE`.
- **Autovectores y autovalores:** en el resultado de R, los **autovectores** son las cargas y los **autovalores** son la varianza de cada componente. Un autovalor grande indica un componente importante. Con datos estandarizados, los autovalores suman la cantidad de variables.

LA IDEA GEOMÉTRICA: ROTAR LOS EJES

El PCA puede verse como una rotación de los ejes del sistema de coordenadas. Los ejes originales son nuestras variables (Variable 1, Variable 2, ...). El PCA los gira para encontrar nuevos ejes alineados con las direcciones de máxima variabilidad de los datos.



- **CP1 (primer componente):** la dirección en la que los datos más se estiran, es decir, la de máxima varianza.
- **CP2 (segundo componente):** la dirección de máxima varianza que queda, y que además es perpendicular (ortogonal) a CP1. Por eso CP1 y CP2 no están correlacionados.
- **CP3, CP4, ...:** se siguen construyendo igual, cada una ortogonal a las anteriores y capturando la varianza restante.

¿CÓMO SE CALCULA? PASO A PASO

1. **Centrar (y estandarizar) los datos.** A cada variable se le resta su media. Si las variables tienen unidades distintas, también se estandarizan.
2. **Calcular la matriz de covarianza** (o de correlaciones, si estandarizamos). Resume cómo se relacionan las variables entre sí.
3. **Calcular autovalores y autovectores de esa matriz.** Los autovectores son las direcciones de los componentes (las cargas) y los autovalores dicen cuánta varianza captura cada uno. Se ordenan de mayor a menor.
4. **Calcular los puntajes (scores).** Se proyectan los datos sobre las nuevas direcciones, y así cada observación pasa a tener sus coordenadas en CP1, CP2, etc.
5. **Medir cuánta información conserva cada componente.** Se divide el autovalor de cada uno por la suma de todos los autovalores. Ese es el porcentaje de varianza explicada.

¿CUÁNTOS COMPONENTES ME QUEDO?

No hay una respuesta única, pero existen criterios habituales. Conviene mirarlos en conjunto:

Criterio	Cómo se usa
Varianza acumulada	Elegir las componentes necesarias para llegar a un porcentaje alto de variabilidad explicada (suele usarse entre 70 % y 90 %). Es la <u>columna Cumulative Proportion de R</u> .
Gráfico del codo (scree plot)	Se grafica la varianza de cada componente y se busca el “codo”, el punto donde la curva deja de caer bruscamente. Nos quedamos con las componentes antes del codo.
Criterio de Kaiser	Con variables estandarizadas, cada variable aporta varianza 1. Se retienen las componentes con autovalor mayor que 1 , porque explican más que una variable original.
Interpretabilidad	Una componente que no podemos interpretar o que no aporta al objetivo del estudio puede no valer la pena, aunque “pase” los criterios anteriores.

EL BILOT: MIRAR OBSERVACIONES Y VARIABLES A LA VEZ

¿Qué es y cómo surge?

Con 2 variables medidas sobre n sujetos, es fácil graficar todo junto: cada sujeto es un punto en un plano con ejes X_1 y X_2 . Pero con m variables ya no podemos dibujar m ejes. Entonces surge la pregunta: ¿cómo representar a la vez m variables y n sujetos? La respuesta es el biplot.

Un biplot es un gráfico que muestra al mismo tiempo:

- Cómo se ubican las observaciones (los sujetos) en las primeras componentes principales: se dibujan como puntos.
- Cómo contribuyen las variables originales a esas componentes: se dibujan como flechas (vectores).

EL BIPLLOT: MIRAR OBSERVACIONES Y VARIABLES A LA VEZ

Pieza	Qué es en PCA	Qué dibuja en el biplot
U-Σ	Los puntajes (scores): la posición de cada observación en CP1, CP2, ...	Los puntos
V	Las cargas (loadings): cuánto pesa cada variable en cada componente (<code>pca\$rotation</code>)	Las flechas
Σ	La "fuerza" de cada componente. Elevada al cuadrado (y dividida por n - 1) da el autovalor, o sea la varianza	El tamaño relativo de cada eje

Cómo se lee


La tabla de datos original se puede reconstruir multiplicando las tres piezas:

$$X = U \Sigma V^T$$

¿Por qué funciona?

El PCA usa una descomposición llamada SVD, que separa la tabla de datos en tres partes: los puntajes de las observaciones (los puntos del biplot), las cargas de las variables (las flechas) y la fuerza de cada componente (su varianza). Como todo sale de la misma cuenta, observaciones y variables se pueden dibujar juntas y leerse en un solo gráfico.

EL BIPLLOT: MIRAR OBSERVACIONES Y VARIABLES A LA VEZ



- La **variabilidad en las variables** (desviación estándar), ya que a mayor longitud del vector mayor error en la variable.
- La **correlación entre variables**, ya que 2 vectores formando ángulo pequeño se interpretan como **variables bien correlacionadas**. Vectores perpendiculares se refieren a **variables con correlación nula** y vectores contrarios a **variables correlacionadas negativamente**.
- **Agrupaciones de casos**: casos próximos tiene valores parecidos de las variables.

EJEMPLO

EJEMPLO:


Supongamos que medimos 5 piezas producidas en una planta industrial, con 3 variables:

- **Longitud** (mm)
- **Ancho** (mm)
- **Peso** (g)

Los datos:

```
R ^

datos <- data.frame(
  longitud = c(10.1, 10.4, 9.9, 10.2, 10.5),
  ancho    = c(5.2, 5.4, 5.1, 5.3, 5.5),
  peso     = c(100, 102, 98, 101, 103)
)
datos
```



	longitud	ancho	peso
1	10.1	5.2	100
2	10.4	5.4	102
3	9.9	5.1	98
4	10.2	5.3	101
5	10.5	5.5	103


Inspección inicial de los datos:

```
R ^

summary(datos)
cor(datos)
```



```
> summary(datos)
      longitud      ancho      peso
Min.   : 9.90   Min.   :5.1   Min.   : 98.0
1st Qu.:10.10   1st Qu.:5.2   1st Qu.:100.0
Median :10.20   Median :5.3   Median :101.0
Mean   :10.22   Mean   :5.3   Mean   :100.8
3rd Qu.:10.40   3rd Qu.:5.4   3rd Qu.:102.0
Max.   :10.50   Max.   :5.5   Max.   :103.0
```



```
> cor(datos)
      longitud      ancho      peso
longitud 1.0000000 0.9933993 0.9907706
ancho    0.9933993 1.0000000 0.9863939
peso     0.9907706 0.9863939 1.0000000
```

EJEMPLO

Aplicar PCA en R

```
R ^  
  
pca <- prcomp(datos,  
  center = TRUE, # centrar las variables  
  scale. = TRUE) # escalar (importante si unidades distintas)
```

Ver los resultados

```
R ^  
  
pca  
summary(pca)
```

```
> pca  
Standard deviations (1, ..., p=3):  
[1] 1.72637732 0.11788784 0.07565576  
  
Rotation (n x k) = (3 x 3):  
      PC1      PC2      PC3  
longitud 0.5780866 -0.1539824 -0.8013147  
ancho    0.5772378 -0.6169210  0.5349813  
peso     0.5767256  0.7718147  0.2677493
```

```
> summary(pca)  
Importance of components:  
      PC1      PC2      PC3  
Standard deviation  1.7264 0.11789 0.07566  
Proportion of Variance 0.9935 0.00463 0.00191  
Cumulative Proportion 0.9935 0.99809 1.00000
```

Qué mirar:

- **Standard deviation** de cada componente → raíz de los autovalores.
- **Proportion of Variance** → proporción de varianza explicada por cada componente.
- **Cumulative Proportion** → acumulada (ideal para decidir cuántos componentes usar).

EJEMPLO

Autovalores y varianza explicada

R ^


```
autovalores <- pca$sdev^2  
autovalores  
prop_var <- autovalores / sum(autovalores)  
prop_var
```

```
> autovalores  
[1] 2.980378664 0.013897543 0.005723794  
> prop_var <- autovalores / sum(autovalores)  
> prop_var  
[1] 0.993459555 0.004632514 0.001907931
```

Interpretación (no exacta, pero razonable para este tipo de datos):

- **PC1** explica la mayor parte de la varianza (por ejemplo, > 80%).
- **PC2** explica una parte menor.
- **PC3** casi nada.

```
#Gráfico del codo  
fviz_eig(pca, addlabels = TRUE, ylim = c(0,  
100), xlab = "Número de componentes",  
ylab = "Proporción de varianza explicada ",  
main = "Método del Codo (Scree Plot)")
```



EJEMPLO

Cargas (loadings) de las variables

```
> pca$rotation
```

	PC1	PC2	PC3
longitud	0.5780866	-0.1539824	-0.8013147
ancho	0.5772378	-0.6169210	0.5349813
peso	0.5767256	0.7718147	0.2677493


- En **PC1**, las tres variables tienen cargas positivas y similares → PC1 representa una especie de **“tamaño general de la pieza”**.
- En **PC2**, ancho y peso se comportan distinto → PC2 puede representar una **diferencia de forma** (más ancho vs más pesado, etc.).

Coordenadas de las observaciones en el espacio de componentes (Librería: factoextra)

```
# Biplot elegante
fviz_pca_biplot(pca,
  repel = TRUE,
  col.var = "red",
  col.ind = "blue",
  title = "Biplot PCA (factoextra)")
```

Interpretación del biplot

- Las **flechas** representan variables originales.
- La **dirección** indica cómo contribuyen a PC1 y PC2.
- La **longitud** indica cuánta influencia tienen.
- Las **observaciones** se ven como puntos.
- Si una observación está cerca de una flecha → esa variable la caracteriza.



CUIDADOS Y LIMITACIONES DEL PCA

Cuidado	Por qué importa
Escalar o no escalar	Con variables en unidades distintas, hay que estandarizar ; si no, domina la variable con valores numéricamente más grandes. Si todas están en la misma unidad, a veces se decide no escalar (depende del objetivo).
Solo capta relaciones lineales	Los componentes son combinaciones lineales. Si la estructura de los datos es curva o muy compleja, el PCA puede no capturarla bien.
Sensible a valores atípicos (outliers)	Un dato muy extremo puede “tirar” de una componente y distorsionar el resultado. Conviene revisar los datos antes.
Necesita variables correlacionadas	Si las variables son independientes entre sí, no hay redundancia que eliminar y el PCA no reduce casi nada.
Los componentes pueden ser difíciles de interpretar	Cada CP mezcla todas las variables. A veces no tiene un significado claro y hay que analizar las cargas con cuidado.
No es selección de variables	El PCA no descarta variables originales: crea combinaciones de todas ellas. Si quisiéramos medir menos variables en el futuro, el PCA por sí solo no lo resuelve.
Varianza ≠ importancia para tu pregunta	El PCA conserva la varianza , pero lo más variable no siempre es lo más relevante para el problema. Es una herramienta exploratoria, no una verdad absoluta.
Datos faltantes	Las funciones estándar no admiten valores NA : hay que eliminarlos o imputarlos antes.

13. Receta rápida para aplicar un PCA

1. **Explorar los datos:** revisar la estructura, los valores faltantes y los outliers (`summary()`, gráficos).
2. **Mirar las correlaciones** (`cor()`): si hay variables muy correlacionadas, el PCA tiene sentido.
3. **Decidir si se estandariza** (casi siempre sí, si hay unidades distintas) y ejecutar `prcomp(datos, scale. = TRUE)`.
4. **Ver cuánta varianza explica cada componente** (`summary(pca)`, `fviz_eig()`) y decidir cuántos componentes retener.
5. **Interpretar las cargas** (`pca$rotation`): ¿qué variables pesan en cada componente? ¿Qué representa cada CP?
6. **Graficar el biplot** (`fviz_pca_biplot()`) para ver observaciones, variables y posibles grupos.
7. **Usar los resultados:** los scores (`pca$x`) pueden usarse como nuevas variables para visualizar, agrupar o alimentar un modelo.

Gracias :)